

RNN y LSTM

Autocompletado en español

Base de Conocimiento / ESPOCH
Grupo 5 / 6 de octubre de 2026

Angel David Gadvay Cepeda · Walter Padilla
Jaime Morales · Jose Nieto
Bryan Lema · Max Viteri



Predicción de la siguiente palabra

el presidente del gobierno

Contexto: palabras ya escritas

Sugerencia observada	Probabilidad del modelo
de	13,77 %
del	7,35 %
vasco	3,00 %

Se muestran tres de las cinco sugerencias de una consulta guardada.

Utilidad

Apoyo a la escritura en editores y formularios.

La persona elige si acepta una propuesta.

RNN: actualización del estado


Paso	Palabra	Operación
1	el	Actualizar con el estado inicial
2	gobierno	Combinar palabra y estado anterior
3	anunció	Actualizar y preparar la predicción

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

Mismos pesos en cada paso. Estado de 64 valores.

Dificultad: conservar información a través de muchas actualizaciones.

LSTM: memoria regulada por compuertas



Celda nueva = información retenida + información incorporada

Cada compuerta aprende cuánto regular. La ventana limita el contexto disponible.

Datos en español y separación por documento

Partición	Documentos	Objetivos usados
Entrenamiento	1 268	100 000
Validación	173	52 695
Prueba	194	56 796

3 000

entradas del vocabulario

Minúsculas y tildes conservadas
Números normalizados y puntuación omitida
Documentos distintos en cada partición

Fuente: UD Spanish-AnCorr r2.17. Particiones propias. Licencia CC BY 4.0.

Código: recorrido de una entrada

[2, 5, 46, 11, 42]

BOS, el, presidente, del, gobierno

Etapa	Salida
Embedding	48 valores por entrada
RNN o LSTM	64 valores por estado
Capa de salida	3 000 puntuaciones
Softmax	Probabilidades por palabra

Bibliotecas

PyTorch
Modelos y entrenamiento

NumPy
Matrices y muestreo

Matplotlib
Gráficas de resultados

Comparación bajo un mismo protocolo

Configuración	Comparación principal
Arquitecturas	RNN y LSTM, frente a un bigrama
Contexto máximo	12 posiciones anteriores
Repeticiones	Semillas 17, 29 y 43
Entrenamiento	5 épocas, lotes de hasta 512
Selección	Menor pérdida de validación

Validación selecciona el modelo. Prueba mide el resultado final.

Exploración adicional: contextos 4 y 24 con una sola semilla.

Qué mide cada resultado


Medida	Pregunta que responde	Mejora
NLL / perplejidad	¿Qué probabilidad recibe la respuesta?	Menor valor
Top-1 léxico	¿La respuesta aparece primero?	Mayor %
Top-5 léxico	¿Aparece entre los cinco primeros?	Mayor %

Ejemplo didáctico


Respuesta en el puesto 4: top-1 falla y top-5 acierta.

La RNN obtuvo mejores medias en esta prueba

Perplejidad · menor es mejor



Top-5 léxico (%) · mayor es mejor




Ganancia top-5 frente al bigrama: RNN +0,96 puntos porcentuales.

Medias de tres semillas para las redes. Prueba: 56 796 objetivos.

El aprendizaje mejora, pero la cobertura limita

LSTM seleccionada para la demo



21,19 %

de objetivos de prueba
fuera del vocabulario

12 033 de 56 796
Palabras agrupadas como
UNK

Menor pérdida de validación en la época 5. La cobertura sigue siendo limitada.

Demostración del autocompletado

Entrada: el presidente del gobierno

Sugerencia	Probabilidad
de	13,77 %
del	7,35 %
vasco	3,00 %
es	1,97 %
se	1,97 %

1. Ejecutar la demo

2. Probar otro contexto

3. Revisar desconocidas

Riobamba ESPOCH Chimborazo

Modelo LSTM seleccionado por validación. Tabla: salida guardada para consulta.

Conclusiones del estudio

La RNN obtuvo mejores medias en las condiciones evaluadas

La celda LSTM regula la información del contexto.
El vocabulario limita las palabras que puede proponer.
La mejora observada corresponde a este experimento.

12 fuentes abiertas y resultados verificables
Informe completo y guía de aprendizaje en el paquete del grupo